УДК 004.032.26

Влияние распределения шума и бюджета на эффективность повторных оценок в роевой оптимизации

Эксперимент на фиксированном наборе тестовых функций

А. А. Инкижеков

Абакан, Российская Федерация

Аннотация. На фиксированном наборе тестовых функций исследовано влияние распределения шума, бюджета и размера роя на повторное оценивание в PSO (алгоритм роя частиц). Алгоритм PSO-OCBA (оптимальное распределение вычислительного бюджета) сопоставлен с однооценочным PSO, PSO-EA (равномерное распределение оценок) и PSO-OCBA-RS (ранжирование и выбор). Расширенная серия содержит 77 760 поисков на восьми функциях при четырех распределениях шума с одинаковыми первыми двумя моментами. Последующий исследовательский анализ 23 контрастов поддерживает взаимодействия формы шума с методом и бюджетом; средний выигрыш к PSO-EA положителен также при нормальном шуме. По отдельному плану до новых наблюдений выполнено 2880 поисков на 16 новых преобразованиях тех же функций. На этом фиксированном наборе разность эффектов логнормального и нормального шума равна 1,1668, совместный 95% доверительный интервал [0,9621; 1,3714]. Иерархическая перевыборка дает приблизительно [-3,02; 5,35]; это не популяционный доверительный интервал, перенос на произвольную функцию не установлен. При обоих шумах PSO-OCBA уступает PSO-OCBA-RS в среднем. В 8208 подтверждающих поисках на двух табличных наборах и малом MLP (многослойный перцептрон) положительное преимущество в 1 процентный пункт точности не установлено. Вклад - условная эмпирическая карта; причинный механизм абляцией и диагностикой не установлен. Аналитические эффекты выражены в нормированных единицах качества.

Ключевые слова: роевая оптимизация, PSO-OCBA, повторное оценивание, вычислительный бюджет, ненормальный шум, размер роя, статистическая мощность

Effects of noise distribution and evaluation budget on particle swarm optimization reevaluation on a fixed set of test functions

A. A. Inkizhekov

Abakan, Russian Federation

Abstract. On a fixed set of test functions, we study how noise distribution, budget and swarm size affect reevaluation in PSO (particle swarm optimization). PSO-OCBA (optimal computing budget allocation) is compared with single-evaluation PSO, PSO-EA (equal allocation) and PSO-OCBA-RS (ranking and selection). The expanded series contains 77,760 searches on eight functions under four noise distributions with matched first two moments. An exploratory analysis of 23 mean contrasts supports interactions of noise shape with method and budget; the mean advantage over PSO-EA is also positive under Gaussian noise. A separate plan fixed before new observations covers 2,880 searches on 16 transformations of the same functions. On these fixed instances, the lognormal-minus-Gaussian interaction is 1.1668, with a simultaneous 95% confidence interval [0.9621, 1.3714]. Hierarchical resampling yields approximately [-3.02, 5.35], not a population confidence interval; transfer to arbitrary functions is not established. PSO-OCBA has lower mean quality than PSO-OCBA-RS under both noises. In 8,208 confirmatory searches on two tabular datasets with a small MLP (multilayer perceptron), a positive one-percentage-point accuracy advantage is not established. Ablation and record diagnostics do not establish a causal mechanism. Analytical effects use normalized quality units. The contribution is a conditional empirical map.

Keywords: particle swarm optimization, optimal computing budget allocation, reevaluation, nonnormal noise, swarm size, evaluation budget, power analysis

Введение

При подборе гиперпараметров качество одной конфигурации меняется из-за инициализации весов и порядка обучающих примеров. Повторы уточняют среднее качество,

но уменьшают число исследованных конфигураций. При фиксированном числе обучений это создает компромисс между исследованием пространства и надежностью сравнения [3, 6, 8, 9, 15]. Ошибки выбора личных и глобального рекордов особенно существенны для PSO, поскольку эти рекорды определяют последующие движения частиц [1, 2].

Ресэмплинг и гибридные способы учета шума ранее исследованы Rada-Vilela и соавторами [3, 4]. Zhang и соавторы предложили PSO-OCBA с учетом обоих типов рекордов [5]. Их алгоритм и принцип распределения ресурса не являются новизной настоящей работы. Исследуются конечные бюджеты от 60 до 8640 оценок. Стартовая оценка дисперсий может расходовать существенную часть малого бюджета, а увеличение общего ресурса не устраняет автоматически влияние размера роя и распределения шума.

Научный вклад состоит в количественных результатах о совместной зависимости эффективности повторов от распределения шума, бюджета и размера роя при одинаковых первых двух моментах. Новые элементы - прямые парные контрасты между стандартизованными шумами, отдельная проверка выбранного контраста на новых преобразованиях и контроль PSO-OCBA-RS, отделяющий пользу повторов от пользы модели личных рекордов. Ненормальные испытания сами по себе не новы: Zhang и соавторы [5] уже использовали шум хи-квадрат с двумя степенями свободы. Новый алгоритм и универсальная закономерность не заявляются.

Компромисс между точностью ранжирования и глубиной поиска не является новой идеей. Wang и Lu [19] исследуют его для эволюционных стратегий и предлагают интегрировать неопределенность в веса отбора с адаптивным переключением. Настоящая работа рассматривает другую постановку: конечнобюджетную проверку PSO-OCBA с контролями PSO-EA и PSO-OCBA-RS. Здесь не выводится новый принцип управления оптимизатором и не сравнивается эффективность с RB-PEM (PEM - probabilistic elite membership; RB - residual bootstrapping).

Современные стратегии обучения частиц систематизированы Chauhan и соавторами [24]. Zhong и соавторы [25] рассматривают неопределенность идентификации параметров из-за случайных измерительных ошибок посредством APSO-SPC (APSO - advanced particle swarm optimization; SPC - stochastic perturbation collocation). Это другой уровень постановки: здесь проверяется распределение повторных вызовов фиксированной шумной функции. Ни обзорные варианты PSO, ни APSO-SPC не включены в экспериментальные контроли и не объявляются уступающими PSO-OCBA.

В исходной аналитической серии случайный поиск (Random) включен как базовый контроль [7]. Прикладная часть следует постановке гиперпараметрического поиска, в которой обучение модели входит в стоимость оценки конфигурации [16].

Постановка задачи и калибровка шума

Максимизируется ожидаемое качество f(x), x в единичном гиперкубе. Один вызов стохастической функции Y(x) стоит одну единицу бюджета B. Для аналитических задач используется нормированное отрицательное значение функции потерь:

$$f(x) = \frac{-L(z)}{s_L}, \quad z = (x-a)Qh \tag{1}$$

В (1) z=(x-a)Qh - преобразованные координаты; a - фиксированный внутренний оптимум, Q - ортогональная матрица, h - масштаб области, s_L - выборочное стандартное отклонение L на 4096 равномерных калибровочных точках. Для каждой пары функции и размерности эти

величины фиксированы и одинаковы для всех методов, уровней шума и бюджетов. Калибровка относится к построению тестовой задачи, выполняется вне поискового бюджета и не передается оптимизатору как оракул.

$$Y(x) = f(x) + \eta(0.6 + 0.8x_1)\xi, \quad \xi \sim N(0,1) \tag{2}$$

Независимые нормальные ошибки имеют стандартное отклонение от 0,6 η до 1,4 η. Разброс сигнала на калибровочном дизайне равен единице; поэтому η=0,25, 1, 2 описывает слабый шум, шум масштаба сигнала и сильный шум. Средний по равномерной области квадрат множителя шума равен 1,05333, а соответствующий шумовой разброс приблизительно равен 1,0263 η. Это определение относится к полному исходному домену, а локальный разброс посещаемых конфигураций может отличаться.

Таблица 1 - Аналитические задачи и преобразования

Функция	Свойство	h	Роль
Sphere	Квадратичная	8	Обучение правила
Ellipsoid	Число обусловленности 10^6	10	Обучение правила
Rosenbrock	Изогнутая долина	4	Обучение правила
Ackley	Мультимодальная	10	Обучение правила
Rastrigin	Мультимодальная	10	Обучение правила
Griewank	Мультимодальная	30	Обучение правила
Levy	Мультимодальная	10	Проверка переноса
Zakharov	Неразделимая	10	Проверка переноса

Примечание. Для каждой функции d=3 и d=8; оптимум a выбирается в $[0{,}25;\ 0{,}75]^d$. После сдвига и поворота задачи не совпадают с каноническими осевыми областями [11]. В Rosenbrock используется u=1+z, в Levy y=1+z/4, чтобы минимум z=0 имел L=0. Все формулы и матрицы сохранены в коде и метаданных.

Столбец роли относится к исходному дереву выбора метода из приложения Б. В расширенной серии и анализе средних все восемь функций являются фиксированными стратами при d=8; роль в дереве не означает внешней валидации новых взаимодействий.

Качество выбранного решения оценивается без шума; нормированный regret (потеря качества относительно оптимума) равен -f(x), поскольку известный оптимум имеет f=0. Оракульное значение применяется только для итоговой оценки и диагностики ошибок. Распределение повторов и выбор конфигурации используют исключительно наблюдения Y.

Методы и реализация PSO-OCBA

Варианты PSO синхронны и используют одинаковую инициализацию с коэффициентами 0,729 и 1,49445. Начальные скорости равномерны в [-0,1; 0,1], каждая координата ограничена [-0,2; 0,2], позиции проецируются на [0; 1]. Размеры роя основной сетки равны 6, 12 и 24. Обновление скорости и позиции сохраняет стандартную форму [1, 2]:

$$v_{i,t+1} = \omega v_{i,t} + c_1 r_{1,i,t} \odot (p_{i,t} - x_{i,t}) + c_2 r_{2,i,t} \odot (g_t - x_{i,t}), \tag{3}$$

$$x_{i,t+1} = clip(x_{i,t} + v_{i,t+1}, 0, 1). \tag{4}$$

В (3)-(4) p и g обозначают координаты личного и глобального рекордов, v - скорость частицы; случайные векторы r независимы и равномерны на [0; 1]. В модели распределения ресурса качество личного рекорда обозначается q_i, а выборочная дисперсия наблюдений - s_i^2. Обозначения координат, скорости и скалярного качества не совмещаются.

Таблица 2 - Контроли и исходные параметры при M=6

Метод	Начальные повторы	Ресурс поколения	Дополнительные оценки
Random	1	Не применимо	Новые случайные точки
PSO	1 на точку	6	Нет
PSO-R3 (три оценки точки)	3 на точку	18	Нет
PSO-EA	3 на точку	36	Равные доли
PSO-OCBA-RS	3 на точку	36	Обычная OCBA выбора лучшего
PSO-OCBA	3 на точку	36	Личные и глобальный рекорды

Примечание. PSO-EA использует равномерное распределение оценок (equal allocation, EA). PSO-OCBA-RS использует обычную OCBA для выбора одной лучшей альтернативы (ranking and selection, RS), без учета личных рекордов в правиле распределения ресурса.

В основных схемах с повторами сначала получают n_0 наблюдений каждой из M новых точек, затем распределяют остаток бюджета поколения 6M порциями M. После первого поколения к текущим точкам добавляется прежний глобальный рекорд с сохранением накопленных наблюдений. Счетчик точки не уменьшается. PSO-EA использует тот же состав альтернатив и частоту поколений, что и обе OCBA ветви. PSO-R3 применяется в исходной серии приложения Г.

В условной гауссовой модели [5] μ_i обозначает выборочное среднее альтернативы i, s_i^2 - выборочную дисперсию, q_i - зафиксированную оценку качества личного рекорда, α_i - долю ресурса. Центр c - лучшая по наблюдаемому среднему альтернатива среди текущих точек и прежнего глобального рекорда. Скорости ошибок сравнения с личным порогом и с центром:

$$R_i(\alpha) = \frac{\alpha_i(\mu_i - q_i)^2}{2s_i^2} \tag{5}$$

$$R_{ic}(\alpha) = \frac{(\mu_i - \mu_c)^2}{2\left(\frac{s_i^2}{\alpha_i} + \frac{s_c^2}{\alpha_c}\right)} \tag{6}$$

Личные ограничения (5) включаются для текущих частиц с существующим рекордом, глобальные (6) - для всех альтернатив, отличных от c. На первом поколении личных порогов нет. На шаге распределения решается задача:

$$max_\alpha min\{R_i(\alpha), R_{ic}(\alpha)\}, \Sigma_i \alpha_i = 1, \alpha_i > 0 \tag{7}$$

Неопределенность адаптивно выбранных личных рекордов отдельно не моделируется: их оценки условно фиксированы на шаге распределения. Формулы (8)-(9), регуляризация, целочисленное дополнение счетчиков и обоснование скалярной редукции приведены в приложении В. Эти ограничения модели сохраняются при ненормальном шуме.

Подробные исходные таблицы, предварительная NN (neural network, нейронная сеть) серия, математическое обоснование, полные веса контрастов и дополнительные проверки вынесены в отдельные материалы с приложениями А-З. Они составляют единый комплект с основной рукописью.

Протокол и критерии сравнения

Каждая серия имеет собственный локально зафиксированный протокол с параметрами, seed и контрольными суммами. Это документирование до наблюдений соответствующей

серии, а не публичная пререгистрация. Случайные потоки движения и наблюдений раздельны. Общие поисковые seed сохраняют парность методов и условий внутри фиксированной функции. Далее max-t (максимум модулей стандартизованных статистик) обозначает процедуру построения совместных интервалов.

Исходная серия с M=6 и B<=540 мотивирует расширение; подробности находятся в приложении Г. Основная расширенная семья содержит 1296 двусторонних ранговых сравнений PSO-OCBA с PSO и PSO-EA, вторичная - 648 сравнений с PSO-OCBA-RS; у каждой своя общая поправка Holm. Описательный критерий ячейки - Holm p<0,05 для отличия от нуля и точечное среднее не менее 0,02. Числа таких ячеек являются описательными счетчиками сочетания двух условий, а не числом статистически доказанных превышений порога 0,02.

В аналитических сравнениях перед ранжированием парные разности округляются до 12 десятичных знаков. Используется SciPy 1.17.0, wilcoxon с zero_method='wilcox', method='auto', двусторонней альтернативой и без поправки непрерывности [17]. Нулевые разности исключаются из ранжирования, связки абсолютных ненулевых разностей получают средние ранги. При всех нулевых разностях p=1 задается явно, а сравнение сохраняется в семье Holm. При 30 парах отсутствие нулей и связок приводит к точному расчету; их наличие - к нормальной аппроксимации с поправкой дисперсии на связки. В новой основной семье 1152 точных расчета, 72 аппроксимации и 72 полностью нулевых сравнения. Эти правила не требуют нормальности исходных ошибок, но не устраняют предпосылку симметрии парных разностей для интерпретации Wilcoxon. Реализация SciPy описана в [22].

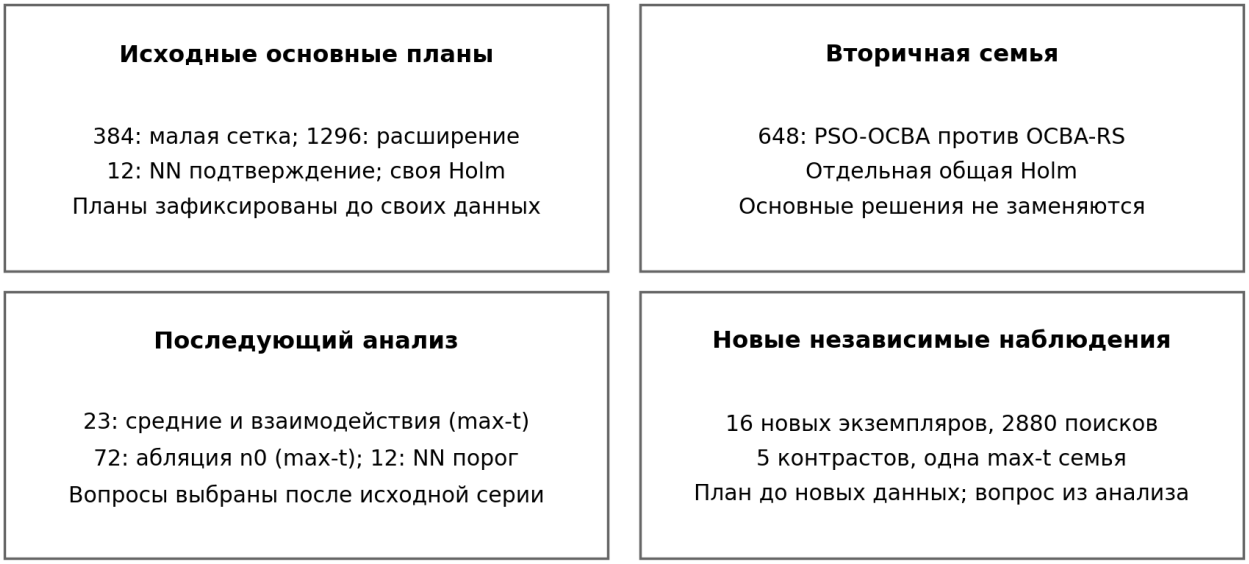


Рисунок 1 - Раздельные семьи и временной статус анализов. План проверки новых экземпляров зафиксирован до новых наблюдений; ее гипотеза выбрана по исходному последующему анализу.

Таблица 3 - Семьи сравнений и временной статус

Семья	Число	Статус	Поправка / процедура	Раздел
Основная расширенная	1296	План до наблюдений	Wilcoxon + Holm	Основной протокол
OCBA против RS	648	Отдельная вторичная	Wilcoxon + Holm	Основной протокол
Средние формы шума	23	Исследовательская, после данных	Одношаговый max-t	Прямое сравнение; E
Абляция n0	72	Исследовательская	Одношаговый max-t	Абляция; Д, E
NN к нулю / к 1 п.п.	12 / 12	План к нулю; уточнение порога после серии	Отдельные Holm; верхние границы Bonferroni	NN проверка

Семья	Число	Статус	Поправка / процедура	Раздел
Новые экземпляры	5	Новый план до новых данных; вопрос выбран ранее	Одношаговый max-t	Новые экземпляры
Исключение семейств	40	Исследовательская	Одношаговый max-t	Приложение Ж
Иерархический сценарий	5	Исследовательская чувствительность	Одношаговый max-t	Приложение Ж

Примечание. п.п. означает процентный пункт. Семьи не объединяются в одну общую процедуру. Проверка NN против нуля и проверка превышения 1 п.п. используют по 12 контрастов с раздельным Holm; совместные верхние границы имеют отдельную поправку Bonferroni на 12. Диагностика иерархии повторяет те же пять координат и не создает новую подтверждающую семью. Исторические семьи 384, дополнительные 192 и NN 120 описаны в приложениях А, Б и Г; анализ знаков - чувствительность к критерию. LOFO (leave-one-family-out, исключение одного семейства функций) и иерархический сценарий исследовательские.

Интервалы средних и парных эффектов (ДИ - доверительный интервал) получены процентильным бутстрепом из 4000 выборок. Они точечные, без одновременного покрытия всей сетки. При усреднении фиксированного набора функций seed пересэмплируются внутри каждой пары функции и размерности. Условия с общим seed сохраняются единым блоком. Интервалы описывают вариацию запусков на этих задачах, но не вариацию случайной популяции задач [9]. При 30 запусках грубая консервативная погрешность 95% оценки вероятности успеха может достигать около 0,18; отсутствие значимости не устанавливает эквивалентность.

Статистический вывод о превышении 0,02 делается по нижней совместной границе среднего. Все пять средних исследовательской семьи 23 имеют границу выше 0,02. Заявленные приближенные 95% относятся к двусторонней области всей семьи из 23 контрастов. Использование ее нижних концов для пяти односторонних выводов консервативно; отдельная 95% односторонняя процедура не вводится. Это вывод о средних по фиксированной сетке, не о каждой ячейке; Wilcoxon и критерий знаков такую проверку среднего не заменяют.

Основная расширенная серия

Исходная гауссова серия при рое из шести частиц и B≤540 не устанавливает преимущества адаптивного распределения над равномерным. Поэтому расширение проверяет три отдельных ограничения этого результата: больший ресурс, иной размер роя и ненормальные ошибки при той же дисперсии. Оно оценивает чувствительность прежнего алгоритма, не подстраивая OCBA под истинное распределение шума.

Дополнительный протокол зафиксирован до наблюдения этой основной серии. Он сохраняет восемь функций и их преобразования, использует d=8, размеры роя M=6, 12, 24 и бюджеты B=540, 2160, 8640. Сравниваются четыре варианта: PSO, PSO-EA, PSO-OCBA-RS и PSO-OCBA. Для PSO-EA, PSO-OCBA-RS и PSO-OCBA бюджет поколения равен 6M, начальные оценки каждой новой точки n_0=3, шаг распределения M. Контроли имеют одинаковый состав альтернатив и частоту новых поколений; однооценочный PSO расходует M оценок на поколение.

Таблица 4 - Объем дополнительной серии

Серия	Задачи	Рой M	Бюджет B	Запуски на метод
Аналитическая	8 функций, d=8	6; 12; 24	540; 2160; 8640	30
Нейросетевой пилот	2 набора x 3 разбиения	12	540	24
Нейросетевая основная	2 набора x 3 разбиения	12	540	456

В (2) нормальная случайная величина заменяется стандартизованной Z. Для нормального шума $Z_N \sim N(0,1)$; для Student t3 (распределение Стьюдента с тремя степенями свободы) $Z_T = \frac{T_3}{\sqrt{3}}, T_3 \sim t(3)$. Для центрированного логнормального шума $Z_L = \frac{e^G - e^{1/2}}{\sqrt{e(e-1)}}$, $G \sim N(0,1)$. Для редких выбросов $Z_C = \frac{H}{\sqrt{5,95}}$; распределение H есть смесь с вероятностью 0,95 нормального N(0,1) и с вероятностью 0,05 нормального N(0,100), где вторые параметры - дисперсии.

Во всех случаях E[Z]=0 и Var[Z]=1. Случаи η=1 и η=2 проверяются для всех четырех семей; η=0 - один раз, поскольку распределение тогда не влияет на наблюдения. Итог - 648 условий и 77 760 поисков, 293 932 800 оценок. Все повторы включены в бюджет.

Нулевой шум составляет отдельный детерминированный контроль: 8640 поисков, то есть 1/9 основной сетки; он не несет информации о форме распределения. При двух ненулевых уровнях проверяются четыре распределения, всего 1+4x2=9 сочетаний. Ненормальные случаи служат стресс-тестом неверно специфицированной гауссовой модели. Формулы ОСВА не превращаются в робастный или адаптированный к распределению алгоритм.

Первоначальные ранговые решения расширенной серии сохранены с общей поправкой Holm по 1296 основным и отдельно по 648 вторичным сравнениям. Условие среднего прироста не менее 0,02 остается точечным описательным критерием. Интервалы по восьми функциям в таблице 5 и на рисунке 2 точечные; их нельзя интерпретировать как одновременные границы всех условий или как интервалы для популяции функций.

Wilcoxon не является прямым тестом равенства средних: его стандартная нулевая модель предполагает симметрию распределения парных разностей относительно нуля [17]. Условие среднего прироста 0,02 применяется отдельно как описательный критерий. Дополнительно выполнен исследовательский анализ чувствительности точным критерием знаков [18], с исключением нулевых разностей и отдельной поправкой Holm по тем же 1296 основным контрастам. Он проверяет вероятность положительной разности среди ненулевых пар без предпосылки симметрии. Из 152 исходных ячеек с описательным критерием относительно PSO-EA этот анализ сохраняет 98. Определение и решения основной семьи Wilcoxon не изменяются.

Таблица 5 - Большой бюджет B=8640 при η=2

Шум	M	К PSO и 95% ДИ	Число ячеек с описательным критерием	К PSO-EA и 95% ДИ	Число ячеек с описательным критерием
Нормальный	6	1,196 [1,025; 1,372]	4	0,277 [0,176; 0,377]	0
Нормальный	12	1,037 [0,872; 1,209]	4	0,132 [0,034; 0,246]	0
Нормальный	24	0,780 [0,622; 0,945]	2	0,002 [-0,076; 0,081]	0
Student t3	6	2,166 [1,992; 2,330]	6	0,853 [0,724; 0,987]	4
Student t3	12	2,221 [2,072; 2,356]	5	0,783 [0,660; 0,908]	4
Student t3	24	2,217 [2,107; 2,328]	5	0,755 [0,609; 0,916]	3
Логнормальный	6	2,416 [2,309; 2,518]	5	1,398 [1,198; 1,601]	5
Логнормальный	12	2,386 [2,278; 2,497]	6	1,433 [1,227; 1,641]	5
Логнормальный	24	2,233 [2,123; 2,344]	6	1,158 [0,962; 1,362]	5
С выбросами	6	2,233 [2,091; 2,373]	6	1,231 [1,076; 1,398]	5
С выбросами	12	2,361 [2,236; 2,483]	7	1,106 [0,980; 1,234]	6
С выбросами	24	2,268 [2,137; 2,393]	6	0,883 [0,775; 0,999]	5

Примечание. Каждая строка усреднена по восьми функциям. Число ячеек с описательным критерием - число отдельных задач с Holm $p<0,05$ и точечным средним не менее 0,02; это не тест превышения 0,02. ДИ относятся к среднему фиксированного набора, счетчики - к отдельным ячейкам.

Число ячеек с описательным критерием в новой основной семье: при $\eta=0$ - 0/72 относительно PSO и 0/72 относительно PSO-EA; при $\eta=1$ - 153/288 относительно PSO и 73/288 относительно PSO-EA; при $\eta=2$ - 155/288 относительно PSO и 79/288 относительно PSO-EA. При $\eta=0$ траектории PSO-OCBA и PSO-EA совпадают; однооценочный PSO при том же seed проходит более длинный префикс той же детерминированной траектории и не дает меньшего качества. При ненулевом шуме сравнение зависит от распределения ошибок и доступного бюджета.

При M=12, B=8640 и $\eta=2$ средний прирост к PSO-EA составляет 0,1322 [0,0345; 0,2463] для нормального шума и 1,4329 [1,2271; 1,6413] для логнормального. Описательному критерию отдельных ячеек соответствуют в 0/8 и 5/8 случаях. Это разделяет эффект среднего по набору и скорректированные сравнения отдельных задач и показывает ограниченность карты, основанной только на уровне дисперсии шума.

Для сопоставления формы шума нулевой уровень исключается из описательных знаменателей: при $\eta=1$ и $\eta=2$ каждому распределению соответствуют 144 условия. Числа ячеек с описательным критерием к PSO-EA составляют 1/144 при нормальном шуме, 37/144 при Student t3, 58/144 при логнормальном и 56/144 при смеси с выбросами. Итого для ненормальных случаев 151/432. Это доли в фиксированной сетке, а не вероятности успеха; они не устанавливают, что форма важнее дисперсии, и не доказывают механизм защиты от выбросов.

Единственная ячейка с описательным критерием относительно PSO-EA при нормальном шуме получена на Ackley при $\eta=1$, M=12 и B=8640: 0,7239 [0,4374; 1,0208], скорректированное $p=0,0167$. Промежуточный бюджет начала этого эффекта не установлен.

Обычная OCBA выбора лучшей альтернативы остается существенным контролем. В отдельной новой семье из 648 сравнений PSO-OCBA имеет 0 ячеек с описательным критерием и 11 значимых проигрышей относительно PSO-OCBA-RS. Поэтому обнаруженный выигрыш над равномерным распределением не следует приписывать доказанному практическому преимуществу модели личных рекордов.

Числа ячеек показывают неоднородность результатов, но не являются прямым тестом влияния формы распределения. Поэтому далее сопоставляются сами парные средние эффекты с сохранением связи seed между шумами, бюджетами и размерами роя.

Увеличение бюджета проверяется при фиксированном числе частиц, а изменение роя - при одинаковом полном числе наблюдений. Поэтому карта показывает совместную роль точности оценок и доступного числа поколений. Изменение среднего эффекта между семьями шума при равной дисперсии свидетельствует о чувствительности проверенного алгоритма к распределению ошибок; отдельный причинный вклад хвостов, асимметрии или редких выбросов этим дизайном не разделен.

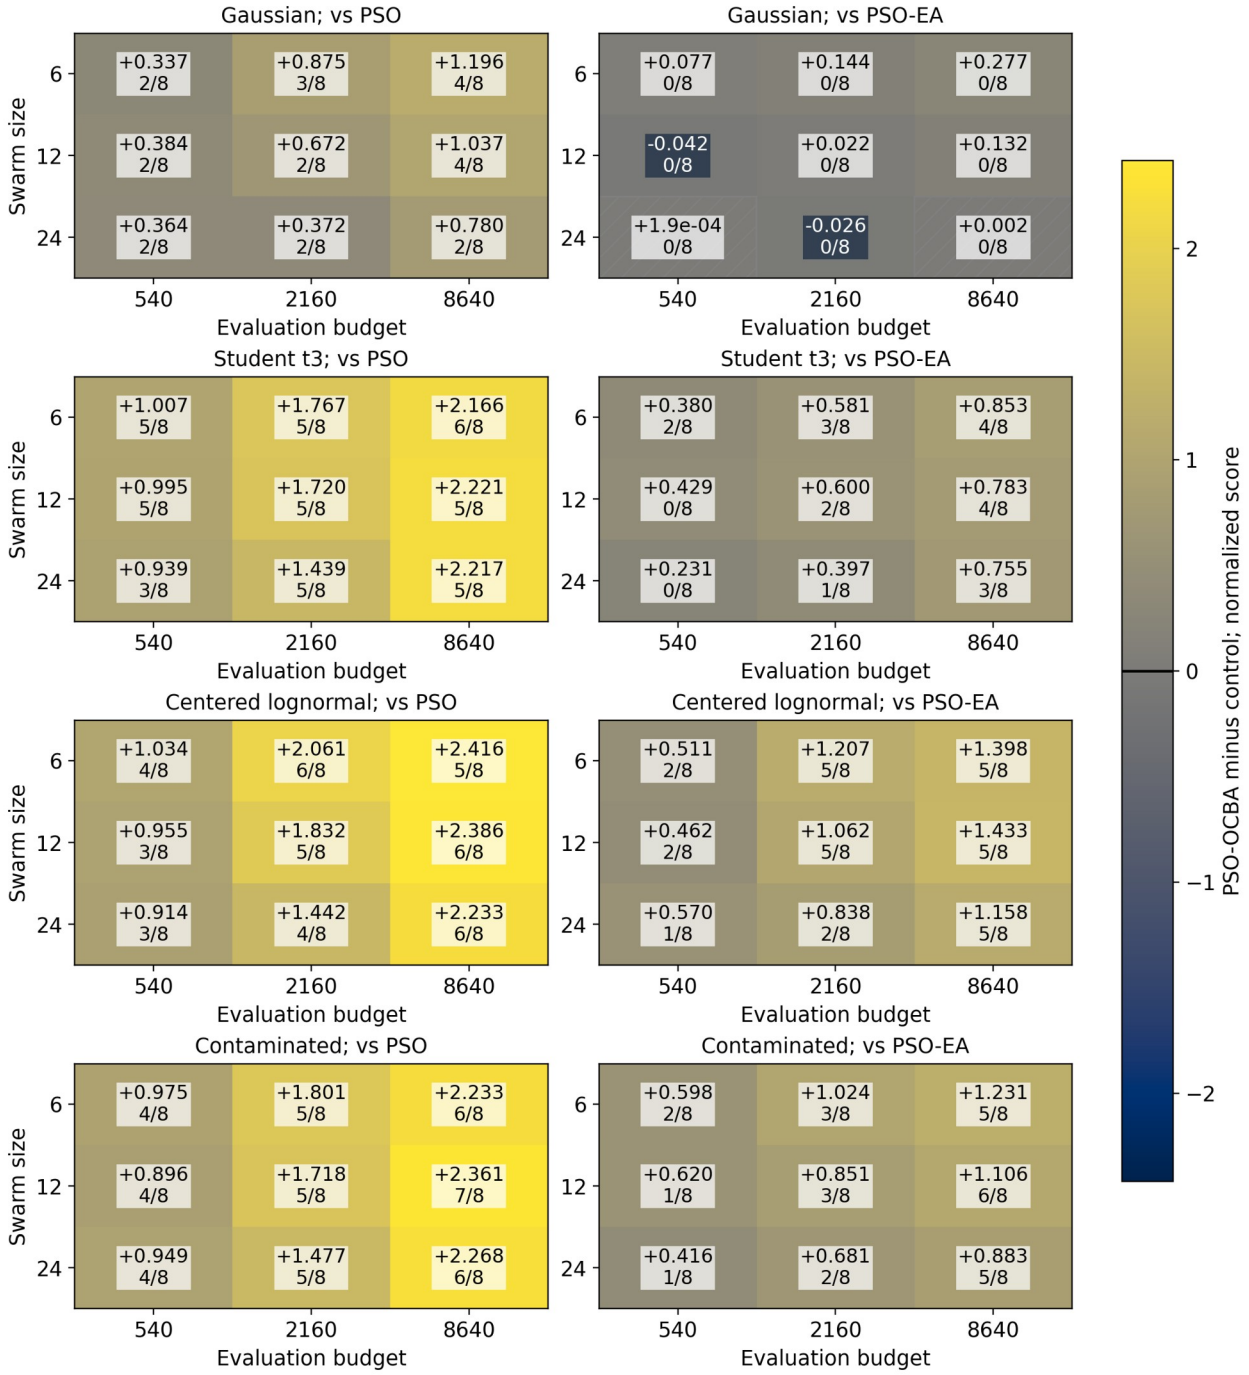


Рисунок 2 - Дополнительная карта при η=2. Число в ячейке - средний прирост по восьми фиксированным функциям; дробь - число ячеек с описательным критерием после общей поправки на 1296 основных сравнений. Палитра cividis с отмеченным нулем; перекрестная штриховка обозначает численный ноль, одинарная - модуль среднего эффекта ниже 0,02. Штриховка не устанавливает эквивалентность.

Прямое сравнение эффектов формы шума

Для каждого условия определим парную разность $D_{f,M,B,\eta,k,s}=Q_{OCBA}-Q_{EA}$. Индексы обозначают фиксированную функцию, размер роя, бюджет, уровень шума, семейство распределения (Gaussian - нормальный шум) и общий поисковый seed. При η>0 сетка содержит 8 функций x 3 роя x 3 бюджета x 2 уровня, с равными весами. Для каждого ненормального семейства оценивается среднее $D_k-D_{Gaussian}$, а также разности этого контраста между бюджетами 2160/8640 и 540, роями 12/24 и 6, уровнями η=2 и η=1. Три контраста формы, шесть бюджетных, шесть роевых, три контраста уровней шума и пять средних D образуют одну исследовательскую семью из 23 контрастов.

Используется 99 999 стратифицированных бутстреп-выборок, seed 10222026. Внутри каждой фиксированной функции совместно перевыбираются 30 полных векторов общих seed. Компоненты по распределениям, бюджетам и роям не перевыбираются независимо; сами восемь функций также не перевыбираются. Стандартная ошибка учитывает вариацию seed внутри каждой функции. Квантиль 0,95 максимума модулей центрированных стандартизованных статистик задает одношаговые совместные интервалы по семье [21]. Это бутстреп-приближение с асимптотическим обоснованием, а не конечновыборочная гарантия или перенос на случайную популяцию функций.

Применяется одношаговый центрированный стандартизованный max-t, а не ступенчатая процедура Romano-Wolf: гипотезы последовательно не удаляются. Работы [21, 23] служат методологическим контекстом совместного вывода на основе перевыборок. Поправка учитывает 23 заданных контраста, но не устраняет выбор исследовательских вопросов после просмотра исходных результатов.

Пятый средний контраст - mean_all - равен одной четверти суммы четырех средних по распределениям, то есть среднему по всем 576 ненулевым условиям с равными весами. Он входит в совместную семью, хотя в таблице 6 показаны только четыре распределения. Полные определения всех 23 и 72 контрастов и их рациональные веса приведены в дополнительных материалах, приложении E, и в двух contrast_ledger CSV/JSON (comma-separated values / JavaScript Object Notation).

Таблица 6 - Парные средние эффекты при η=1 и 2

Шум	Среднее OCBA - EA и совместный 95% ДИ	Превышение над нормальным шумом и совместный 95% ДИ	Число ячеек с описательным критерием
Нормальный	0,0790 [0,0232; 0,1348]	0 по определению	1/144
Student t3	0,4413 [0,3558; 0,5268]	0,3623 [0,2653; 0,4593]	37/144
Логнормальный	0,7678 [0,6477; 0,8879]	0,6889 [0,5578; 0,8200]	58/144
С выбросами	0,6426 [0,5571; 0,7282]	0,5637 [0,4556; 0,6717]	56/144

Примечание. Все интервалы принадлежат исследовательской семье 23 и оценивают среднее по 144 фиксированным условиям каждого шума. Число ячеек с описательным критерием относится к отдельным ячейкам исходной семьи 1296. Положительная граница среднего и малый счетчик ячеек отвечают разным вопросам. Эффекты и границы выражены в нормированных единицах качества, не в процентах.

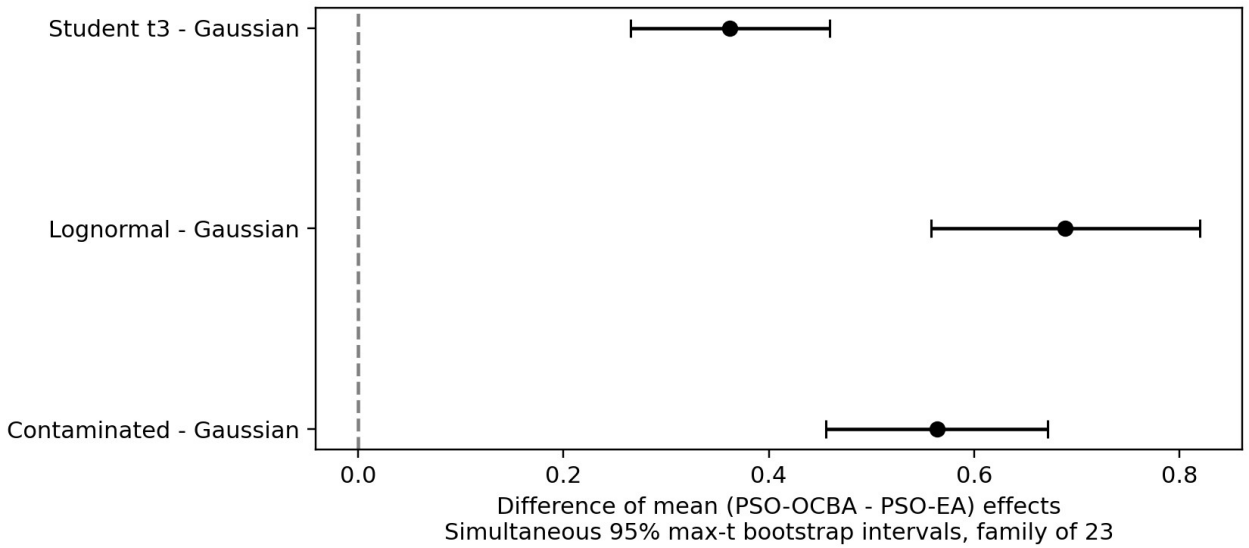


Рисунок 3 - Прямые различия средних эффектов распределений. Горизонтальные отрезки имеют совместное покрытие в исследовательской семье из 23 контрастов.

Все три контраста ненормального шума с нормальным шумом положительны по совместным интервалам. Для изменения этих контрастов между B=540 и B=8640 положительны все три границы; между B=540 и B=2160 положительны две из трех. Все три разности между η=2 и η=1 положительны. Ни один из шести контрастов взаимодействия с размером роя не исключает ноль. Следовательно, данные поддерживают взаимодействия формы шума с методом и бюджетом; дополнительное взаимодействие с роем в этой усредненной постановке не установлено.

Для нормального шума среднее преимущество равно 0,0790 [0,0232; 0,1348]; нижняя совместная граница также превышает 0,02. Это средний эффект по 144 фиксированным условиям, установленный последующим анализом. Он совместим с тем, что лишь одна отдельная ячейка проходит более консервативный исходный ранговый фильтр. Нельзя заключать, что адаптация полезна только при ненормальном шуме. При последовательном исключении каждой функции знаки трех контрастов формы и среднего при нормальном шуме сохраняются, но эти восемь описательных проверок не являются внешней валидацией.

Общее среднее mean_all равно 0,4827 [0,4336; 0,5317]. Оно равномерно усредняет четыре распределения и 576 условий с ненулевым шумом: каждое распределение получает вес 1/4, каждое из его 144 условий - 1/144. Сильные ненормальные эффекты повышают это среднее. Прохождение порога общим средним само по себе не влечет прохождения для каждого распределения. Здесь все четыре отдельные границы также выше 0,02; для нормального шума нижняя граница 0,0232 близка к порогу.

Чувствительность к числу bootstrap выборок: при 9999 и 99 999 критические множители равны 3,1874 и 3,2021, наибольшее изменение границы - 0,00116. Решения об исключении нуля и превышении 0,02 пятью средними не меняются. Для шести взаимодействий с роем последующая описательная оценка MDE90 (minimum detectable effect at 90% power, минимальный обнаруживаемый эффект при мощности 90%) составляет 0,278-0,355 в зависимости от направления и шума. В эмпирической модели к одному целевому среднему добавляется гипотетический аддитивный сдвиг δ при неизменном законе центрированных ошибок, структуре парности и критическом множителе семьи 23. MDE90 - сдвиг, обнаруживаемый в 90% этих симуляций, а не плановая или достигнутая мощность. Неустановленное взаимодействие не исключает меньших эффектов; расчет приведен в приложении Ж.

В 484 из 1296 парных выборок модуль выборочной асимметрии превышает единицу; в 837 есть значения за границами 1,5 межквартильного размаха. Наблюдения не удаляются. Во всех 152 ячейках исходного фильтра средний прирост остается не ниже 0,02 при удалении любой одной пары; это проверка влияния наблюдения, а не тест порога. Вывод о средних основан на совместном бутстрепе и не приписывается ни Wilcoxon, ни критерию знаков.

Сфокусированная абляция начального числа наблюдений

Для Ackley и Rosenbrock при d=8, η=2, M=12 и B=8640 выполнено 2160 дополнительных поисков: четыре шума, n_0=3/5/10, PSO-EA, PSO-OCBA-RS и PSO-OCBA, по 30 общих seed. Эти две функции представляют мультимодальную поверхность и изогнутую долину; абляция является сфокусированной исследовательской проверкой после изучения основной серии. Новая сетка и код зафиксированы до получения наблюдений абляции.

n_0=10 невозможно реализовать для всех частиц при бюджете поколения 6M. Поэтому во всех трех ветвях абляции бюджет поколения равен 12M; каждая проходит ровно 60 поколений и использует ровно 8640 оценок. Число новых точек равно 720. Меняется доля

начальных оценок в поколении: 25%, 41,7% и 83,3%; увеличение n_0 уменьшает ресурс адаптивного дополнения. Дополнительный парный мост n_0=3, 12M против исходного n_0=3, 6M оценивает изменение глубины отдельно. Различия с исходной картой нельзя приписывать только n_0.

Семья содержит 36 средних эффектов трех попарных сравнений, 24 изменения эффекта при n_0=5/10 относительно n_0=3 и 12 контрастов моста поколения. Для всех 72 контрастов совместно применен тот же стратифицированный max-t бутстреп с 99 999 выборками, seed 11222026. Страты - две фиксированные функции; внутри страты сохраняется общий вектор из 30 seed. Результаты не включаются в исходные семьи Holm.

Таблица 7 - Изменение среднего эффекта PSO-OCBA к PSO-EA

Шум	n_0=5 минус n_0=3 и совместный 95% ДИ	n_0=10 минус n_0=3 и совместный 95% ДИ
Нормальный	0,256 [-0,164; 0,675]	0,137 [-0,223; 0,498]
Student t3	-0,040 [-0,438; 0,359]	-0,071 [-0,393; 0,251]
Логнормальный	0,111 [-0,172; 0,393]	-0,266 [-0,566; 0,035]
С выбросами	0,034 [-0,171; 0,240]	-0,205 [-0,458; 0,048]

Примечание. Все интервалы принадлежат одной исследовательской семье из 72 контрастов. Положительное значение означает увеличение преимущества PSO-OCBA при большем n_0.

Ни одно из 24 изменений эффекта не значимо после совместной поправки. Интервалы широки: это отсутствие установленного изменения, а не эквивалентность n_0. Среди 12 средних сравнений PSO-OCBA с PSO-OCBA-RS нет положительного подтвержденного эффекта; при логнормальном шуме и n_0=10 среднее равно -0,299 [-0,584; -0,013], совместно скорректированное p=0,0345. Детали начальных дисперсий и полные интервалы приведены в приложении Д и компактном архиве. Более точная начальная оценка дисперсии сама по себе не устанавливает улучшения конечного решения.

Планирование и выполнение нейросетевой проверки

Подтверждающая серия использует Ionosphere и Sonar [12, 13] и новые стратифицированные разбиения 7101, 7102, 7103. Модель, пространство гиперпараметров, 20 эпох Adam (adaptive moment estimation), разделение train/validation/test и три независимых финальных обучения сохраняются. Для каждого разбиения отдельно сопоставляются PSO, PSO-EA и PSO-OCBA при M=12 и B=540. Единица анализа - полный независимый поиск; три финальных обучения дают одну среднюю test accuracy. Два набора UCI (University of California, Irvine) выбраны до нового пилота для углубленной проверки условий с высокой вариацией и менее выраженным потолком accuracy в предварительной серии. Это целенаправленная проверка выбранных задач, а не случайная выборка нейросетевых приложений.

Ionosphere содержит 351 радиолокационный отклик ионосферы, описанный 34 числовыми признаками; два класса отражают наличие или отсутствие структуры в сигнале [12]. Sonar содержит 208 гидроакустических откликов с 60 признаками энергии в частотных полосах; различаются отражения от металлического цилиндра и камня [13]. Данные получены из UCI. Наборы Digits, Wine и Breast Cancer Wisconsin (Diagnostic) предварительной серии загружены средствами scikit-learn 1.8.0 и кратко описаны в приложении А [28-30].

Оптимизируются ширина единственного скрытого слоя от 16 до 128 с шагом 16, скорость обучения от 10^{-4} до $10^{-1,5}$ и L2-регуляризация от 10^{-6} до 10^{-2}. MLPClassifier

использует ReLU (rectified linear unit), Adam, batch_size=64 и ровно 20 эпох без ранней остановки. Поиск видит только validation accuracy. Стратифицированное разбиение train/validation/test имеет доли 60/20/20; StandardScaler во время поиска обучается на train.

Выбранная конфигурация заново обучается на train+validation с тремя новыми seed, общими для методов внутри поисковой пары. Масштабирование заново оценивается на train+validation без test. Одна итоговая оценка поиска - средняя test accuracy трех моделей; это не три независимых поиска. Финальные обучения учитываются отдельно от поискового бюджета 540.

До основной серии задано увеличение средней accuracy на 0,01, то есть на 1 процентный пункт, и плановая маргинальная мощность 90%. Мощность относится к отклонению гипотезы нулевого эффекта при этой альтернативе. Для 12 основных контрастов используется Holm; при планировании применен консервативный уровень значимости 0,05/12. Независимый пилот содержит 24 поиска каждого метода на каждом из шести условий, всего 432 поиска. Для каждого контраста рассчитана верхняя 95% граница стандартного отклонения парной разности в нормальной модели; для всех условий взят максимум. Средние пилотных эффектов не входят в правило выбора объема. Исходный расчет использует нецентральное t-распределение [17], затем объем увеличивается шагами по 24, пока нижняя 95% граница Wilson для мощности по 10 000 симуляциям не достигнет 0,90 во всех моделях планирования.

Таблица 8 - Мощность в моделях планирования при выбранном объеме

Модель парных разностей	Запуски	Оценка мощности	Нижняя общая 95% граница
Нормальная	456	0,9225	0,9190
Student t3	456	0,9197	0,9161
Наихудшая центрированная пилотная	456	0,9071	0,9032

Примечание. После выбора объема выполнена независимая проверка с новыми seed по 50 000 симуляций для каждой из 14 моделей. В таблице показаны ее результаты, границы Wilson скорректированы Bonferroni на 14 моделей. Дисперсии эмпирических альтернатив в этой проверке точно приведены к одной консервативной верхней оценке. Основные нейросетевые результаты в расчете не использованы; минимальная нижняя граница равна 0,9032.

Наибольшая верхняя оценка стандартного отклонения равна 0,04954 accuracy. Итоговый объем 456 независимых пар на условие зафиксирован до основной серии: 8 208 поисков, 4 432 320 поисковых обучений и 24 624 отдельных финальных обучений. Seed основной серии не пересекаются с пилотом и исторической серией. Основной критерий - двусторонний парный t-тест средней accuracy, эквивалентный одновыборочному t-тесту парных разностей. Для отчета ячейка с описательным критерием требует точечной оценки не ниже 1 процентного пункта и $p<0,05$ после Holm. Критерий проверяет отличие от нуля, а не превышение 1 процентного пункта. Он зафиксирован до пилота вместе с правилом мощности. Это приближение для средних независимых ограниченных разностей; моделирование проверяет нормальную, Student t3 и 12 центрированных эмпирических альтернатив. Student t3 служит стресс-моделью, а не буквальной моделью ограниченной accuracy. Ранговые сравнения сохранены как вторичный анализ чувствительности.

Таблица 9 - Подтверждающие парные эффекты PSO-OCBA в процентных пунктах

Набор / split	К PSO и 95% ДИ	Скорр. p	К PSO-EA и 95% ДИ	Скорр. p
ionosphere / 7101	-0,018 [-0,136; 0,101]	1	-0,024 [-0,116; 0,068]	1
ionosphere / 7102	0,068 [-0,004; 0,140]	0,451	0,031 [-0,034; 0,096]	1
ionosphere / 7103	-0,069 [-0,246; 0,108]	1	-0,119 [-0,249; 0,010]	0,451
sonar / 7101	-1,133 [-1,336; -0,931]	5,08e-24	-0,188 [-0,376; 0,000]	0,401
sonar / 7102	-0,856 [-1,085; -0,628]	9,77e-12	-0,325 [-0,529; -0,122]	0,016
sonar / 7103	0,721 [0,444; 0,997]	4,5e-06	0,094 [-0,180; 0,368]	1

Примечание. p скорректированы Holm по всей семье из 12 основных сравнений. ДИ в таблице точечные; одновременные интервалы Bonferroni с семейным уровнем 95% приведены в архиве. Перекрывающиеся split не объединяются как независимые наборы.

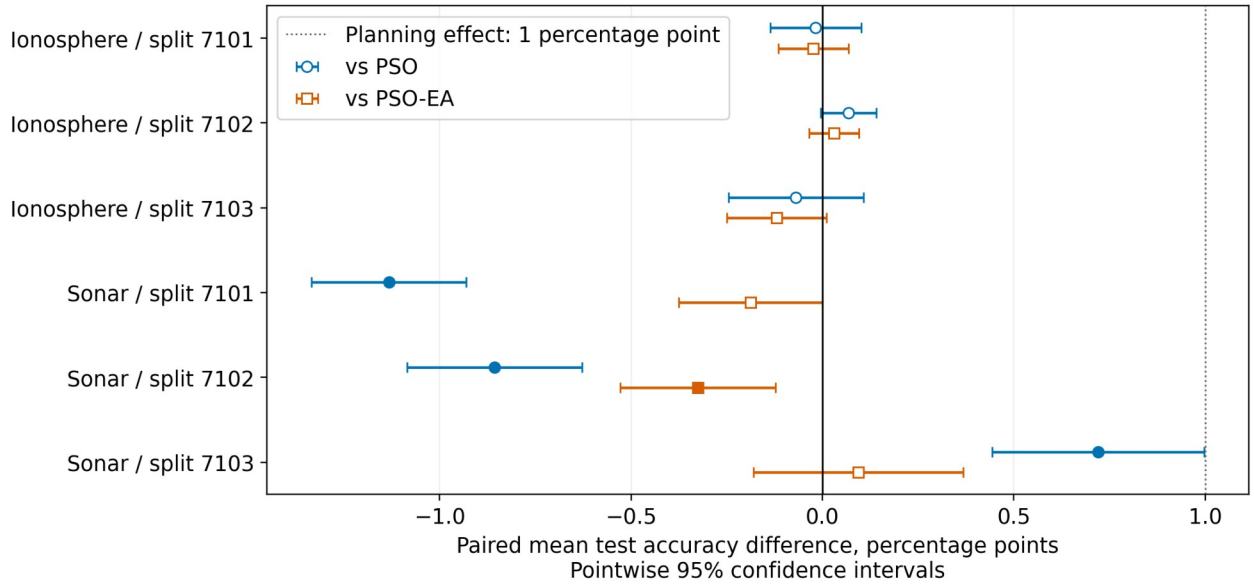


Рисунок 4 - Эффекты в новой нейросетевой серии при M=12 и B=540. Горизонтальные отрезки - точечные 95% ДИ парного среднего; закрашенный маркер означает p<0,05 после Holm по 12 контрастам. Пунктирная линия - плановый эффект 1 процентный пункт. Плановая мощность не является гарантией значимости наблюдаемого эффекта.

После общей поправки значимы 4 из 12 контрастов, практический положительный эффект не менее 1 процентного пункта получен в 0 сравнениях. Направления и интервалы приведены для всех условий. Отсутствие отклонения нулевой гипотезы не доказывает эквивалентность; значимый эффект меньшего размера не удовлетворяет заранее заданному практическому порогу.

На Ionosphere значимы 0 из шести контрастов. На Sonar результат зависит от разбиения: разности PSO-OCBA минус PSO равны -1,133, -0,856 и 0,721 процентного пункта для 7101, 7102 и 7103 соответственно. Первые два эффекта отрицательны, третий положителен; все три проходят Holm. На разбиении 7102 также значимо отставание от PSO-EA на 0,325 процентного пункта. Положительный эффект на 7103 меньше заранее заданного практического порога и не повторяется на двух других разбиениях.

Решения вторичного рангового анализа совпадают с основными по 12 из 12 контрастов. Это анализ чувствительности к выбору критерия, а не дополнительные основные гипотезы.

Дополнительно выполнены 12 исследовательских односторонних t-тестов гипотезы, что средний прирост не превышает 0,01 accuracy, против превышения этого порога. Применена отдельная общая поправка Holm по этим 12 тестам; отклонений нет. Эта последующая проверка порога не подменяет заранее заданные тесты отличия от нуля.

В 11 из 12 контрастов верхняя граница одновременного интервала Bonferroni ниже 1 процентного пункта. Для этих фиксированных условий интервальная оценка ограничивает положительный эффект относительно заданного практического порога. Это не утверждение о нулевом эффекте или эквивалентности на других задачах.

В частности, для 6 из шести сравнений с PSO-EA одновременная верхняя граница положительного эффекта ниже 1 процентного пункта; наибольшая из этих границ равна 0,495 процентного пункта. Этот вывод относится к среднему по независимым поисковым seed при фиксированных данных и архитектуре.

Проверка на новых экземплярах функций

Для независимой от исходных наблюдений проверки выбранного контраста логнормального и нормального шума создано по два новых сдвига и поворота каждой из восьми функций, всего 16 экземпляров. Их параметры и новые поисковые seed заданы отдельными генераторами. Сохранены калибровка на 4096 точках, d=8, eta=2, M=12, B=8640, n0=3 и бюджет поколения 6M. Сравниваются PSO-EA, PSO-OCBA-RS и PSO-OCBA, по 30 парных запусков: 2880 поисков и 24 883 200 вызовов. Однооценочный PSO в этой узкой проверке не исследуется.

До новых наблюдений сохранен отдельный локальный протокол с пятью контрастами: по два средних эффекта PSO-OCBA к PSO-EA и PSO-OCBA-RS для двух шумов и разность эффектов к PSO-EA между шумами. Применена одна совместная max-t семья, 99 999 выборок, seed 12222026; веса 16 фиксированных экземпляров равны 1/16, веса 30 общих seed - 1/30. Все векторы шумов и методов сохраняют парность. Размер серии выбран по вычислительному лимиту, мощность не планировалась. Сама гипотеза выбрана после анализа старых данных; эта новая проверка не переопределяет исходные семьи.

Таблица 10 - Парные средние на 16 новых экземплярах

Контраст	Средний эффект и совместный 95% ДИ	Скорр. p (max-t)
OCBA - EA, нормальный	0,1309 [0,0398; 0,2220]	0,00211
OCBA - EA, логнормальный	1,2977 [1,1084; 1,4869]	0,00001
Разность эффектов: логнормальный - нормальный	1,1668 [0,9621; 1,3714]	0,00001
OCBA - OCBA-RS, нормальный	-0,1223 [-0,2221; -0,0226]	0,01068
OCBA - OCBA-RS, логнормальный	-0,2195 [-0,3058; -0,1333]	0,00001

Примечание. Все пять интервалов совместные. Большее оракульное качество лучше. Это средние по фиксированным экземплярам, а не доказательство доминирования в каждом условии.

Новые наблюдения поддерживают выбранное взаимодействие распределения и метода: превышение эффекта при логнормальном шуме равно 1,1668 [0,9621; 1,3714]. При обоих шумах среднее качество PSO-OCBA ниже PSO-OCBA-RS. Вместе с исходной вторичной семьей это ограничивает практическую пользу модели личных рекордов в проверенных режимах. Два новых преобразования не заменяют новые семейства функций или COCO (COmparing Continuous Optimizers) bbob-noisy (шумные тестовые задачи черного ящика); вывод остается условным относительно 16 фиксированных экземпляров восьми прежних функций.

Последующий анализ показывает положительные точечные контрасты L-G (логнормальный минус нормальный шум) у всех 16 экземпляров, от 0,0776 до 5,4992. При исключении любого семейства целиком средний контраст лежит между 0,6723 и 1,3210; наименьшая совместная нижняя граница равна 0,5245 в отдельной исследовательской семье 40 контрастов. Однако иерархическая перевыборка семейств, экземпляров и seed дает для L-

G интервал [-3,0175; 5,3511]. Это приближенный сценарий обменности всего восьми целенаправленно выбранных семейств, не популяционный доверительный интервал. Результат устойчив на фиксированном наборе, но его перенос на произвольную новую функцию не установлен. Все экземпляры, средние семейств и обе оценки неопределенности показаны в приложении Ж.

Проверка распределения перевыборок воспроизвела этот интервал. Квантили 2,5% и 97,5% самих средних L-G равны 0,3086 и 2,3424, но это описательные квантили, не использованная совместная область. Ее полуширина - квантиль 0,95 максимума модулей центрированных стандартизованных ошибок, умноженный на исходную стандартную ошибку. При восьми неоднородных семействах малые стандартные ошибки отдельных перевыборок увеличивают множитель до 7,5014. Другой seed дает 7,4111, а без перевыборки поисковых seed - 7,2009; широкий размах не вызван только последним уровнем. В верхних 5% стандартизованных ошибок контраста L-G 99,98% перевыборок не содержат Griewank; подробная диагностика приведена в приложении Ж. Более узкий интервал после просмотра данных не выбирался.

Таблица 11 - Ключевые контрасты: PSO-OCBA минус PSO-EA и PSO-OCBA-RS; L-G означает разность эффектов логнормального и нормального шума

Контраст	Эффект и совместный 95% ДИ	Статус и область
OCBA - EA, нормальный шум, исходная сетка	0,0790 [0,0232; 0,1348]	Исследовательский; семья 23, фиксированная сетка
L-G эффектов к EA, исходная сетка	0,6889 [0,5578; 0,8200]	Исследовательский; семья 23, фиксированная сетка
L-G эффектов к EA, новые экземпляры	1,1668 [0,9621; 1,3714]	Новый план до наблюдений; семья 5, фиксированные 16
OCBA - RS, нормальный шум, новые экземпляры	-0,1223 [-0,2221; -0,0226]	Новый план до наблюдений; семья 5, фиксированные 16
OCBA - RS, логнормальный шум, новые экземпляры	-0,2195 [-0,3058; -0,1333]	Новый план до наблюдений; семья 5, фиксированные 16

Примечание. L-G - логнормальный минус нормальный шум; OCBA, EA и RS - соответствующие варианты PSO. Новая проверка имеет независимые наблюдения и локальный план, но выбранный вопрос возник после исходного исследовательского анализа. Ни один интервал не относится к случайной популяции функций.

Обсуждение и ограничения

Повторное оценивание создает компромисс между числом новых точек и точностью их сравнения. В исходной малобюджетной гауссовой серии большую часть среднего выигрыша при η=2 дает уже равномерный контроль; разложение (10) в приложении Г относится именно к этой серии. Дополнительная сетка меняет область применимости вывода: 151 из 152 ячеек с описательным критерием относительно PSO-EA получены при ненормальном шуме. Поэтому результаты исходной нормальной модели не следует переносить только по величине дисперсии. Разложение эффектов описывает наблюдаемое сравнение, а не доказывает отдельный причинный механизм выигрыша.

Основная расширенная серия использует восемь фиксированных функций при d=8 и по одному сдвигу/повороту. Увеличение числа seed не создает новые независимые функции. Совместные интервалы средних условны относительно этой сетки. Изменение роя при равном B меняет число поколений; новые контрасты не устанавливают отдельного взаимодействия формы шума с роем. Абляция n_0 ограничена двумя функциями, η=2, M=12, B=8640 и бюджетом поколения 12M. Ее нельзя переносить на полный диапазон задач или считать эквивалентностью.

Отдельная проверка двух новых преобразований каждой функции уменьшает зависимость вывода о выбранном взаимодействии от единственного исходного сдвига и поворота. Она не проверяет новые семейства задач, другие уровни шума, бюджеты или COCO. Дальнейшее обобщение требует таких данных, а причинная роль ошибки дисперсии, pbest (personal best, личный рекорд) и gbest (global best, глобальный рекорд) остается открытой.

Диагностика 2880 сохраненных трасс воспроизвела все итоговые выборы и счетчики ошибок pbest. При логнормальном шуме доля ошибок pbest равна 42,28% у EA, 35,37% у OCBA и 36,20% у RS. Доли ошибочного выбора gbest равны соответственно 94,80%, 83,34% и 81,06% поколений; выбор сравнивается с лучшим по истинному качеству среди сохраненных личных рекордов, а не со всеми посещенными точками. У OCBA ошибок pbest меньше, чем у RS, но итоговый regret больше: 0,815 против 0,596. Снижение одной частоты ошибок не объясняет ранжирование методов. Точные определения, знаменатели и обработка повторных координат даны в приложении З, формулы (З1)-(З2). Разные посещенные точки и адаптивный выбор не позволяют приписать связям причинный смысл.

Стандартная серия COCO bbob-noisy [20] не использовалась. Новая проверка преобразований тех же восьми функций не заменяет проверку на других семействах задач. Декомпозиция источников вариации обучения остается отдельной задачей. В подтверждающей прикладной серии нет Random Search, TPE (tree-structured Parzen estimator) и более сложных архитектур, поэтому ее вывод не устанавливает конкурентоспособность относительно всего класса HPO (hyperparameter optimization, оптимизация гиперпараметров).

Дополнительная серия проверяет три ненормальные семьи при сохранении независимости, нулевого условного среднего и одинаковой дисперсии. У Student t3 конечна дисперсия, но отсутствует четвертый момент; центрированный логнормальный шум асимметричен, а смесь моделирует редкие крупные ошибки. Гауссово правило OCBA не адаптировалось к истинному распределению. Систематическое смещение, коррелированный шум и шум с бесконечной дисперсией по-прежнему не исследованы. Равенство дисперсий не делает распределения взаимозаменяемыми.

Вопрос устойчивости OCBA к шуму рассматривается Choi и Kim [26], которые предлагают эвристическую корректировку с учетом точности результатов. Байесовские процедуры ranking and selection Chick и Inoue [27] оценивают неопределенность неизвестных средних и дисперсий в иной постановке. Эти методы здесь не реализованы и не сравниваются. Их наличие не позволяет интерпретировать выигрыш гауссовой OCBA на данной сетке как установленную робастность к произвольным распределениям или превосходство над робастными и байесовскими альтернативами.

Ограничение дискретности относится к предварительной нейросетевой серии из шести пар и не переносится на новую подтверждающую серию. Последняя имеет заранее заданный объем, отдельные seed и проверяет среднюю accuracy. Плановая мощность условна относительно оценки дисперсии и моделей альтернативы; она не является измеренной после опыта вероятностью обнаружения эффекта. Цель 90% относится к одному контрасту при консервативном уровне 0,05/12, а не к одновременному обнаружению всех 12 эффектов. Перекрывающиеся разбиения остаются фиксированными условиями, а не независимыми наборами данных. Проверка ограничена двумя табличными задачами и небольшим MLP с Adam; отдельная декомпозиция источников вариации обучения не выполнялась. Интервалы описывают вариацию поиска и обучения при фиксированных train/test, а не неопределенность выбора тестовых объектов из неизвестной популяции.

На Sonar тест содержит 42 уникальных объекта. Одно дополнительное правильное предсказание среди 3x42 ответов трех финальных моделей меняет среднюю accuracy на 100/(3x42)=0,794 процентного пункта. Это 42 тестовых объекта, а не 126 независимых объектов. Повторение поисков уточняет среднее на фиксированном test и не устраняет неопределенность выбора тестовой популяции.

Синтетическая серия задает независимый аддитивный шум с контролируемыми моментами. В MLP наблюдается ограниченная дискретная accuracy, меняются архитектура и траектория обучения, а конечный test отделен от validation. Поэтому подтверждение синтетического взаимодействия само по себе не предсказывает эффект на этих данных; нейросетевая серия проверяет отдельную прикладную гипотезу. Ни общий механизм различий, ни перенос результата на HPO в целом этим дизайном не установлены.

Первичные аналитические и NN серии имеют отдельные локальные планы; наблюдения NN пилота исключены из подтверждающей выборки. Последующий анализ средних и абляция не изменяют первичные решения. Одинаковый B в NN задаче означает одинаковое число обучений, а не равные FLOPs (floating-point operations) или CPU-время (время центрального процессора), поскольку ширина выбранных сетей может различаться.

Заключение

Получена количественная карта опубликованной PSO-OCBA при конечных бюджетах. Прямые парные контрасты отделяют пользу повторов от пользы адаптивного распределения и от PSO-специфической модели личных рекордов. Счетчики отдельных ячеек в описательной части показывают неоднородность сетки и не трактуются как статистическое доказательство превышения 0,02.

Последующий исследовательский анализ средних поддерживает взаимодействия формы шума с методом и бюджетом на восьми фиксированных функциях. Средние преимущества к PSO-EA положительны для четырех распределений, и совместные нижние границы превышают 0,02; для нормального шума эффект равен 0,0790 [0,0232; 0,1348]. Взаимодействие с роем не установлено. Последующая описательная оценка MDE90 в условной модели сдвига составляет около 0,28-0,36; она не является плановой мощностью, доказательством эквивалентности или основанием исключить меньшие эффекты.

По новому плану до наблюдений на фиксированном наборе 16 преобразований прежних восьми функций повторено выбранное различие логнормального и нормального шума: 1,1668 [0,9621; 1,3714]. При исключении каждого семейства совместная нижняя граница остается положительной; само сохранение положительного знака следует также из положительных точечных эффектов всех экземпляров. Последующий иерархический сценарий дает [-3,0175; 5,3511]; это не популяционный доверительный интервал, и перенос на произвольную новую функцию не установлен. При обоих шумах PSO-OCBA уступает PSO-OCBA-RS в среднем на новых экземплярах. Это не универсальное доминирование RS и не доказательство вреда pbest как общего принципа.

Отдельная вторичная семья расширенной серии и новая проверка средних не устанавливают практического преимущества PSO-специфической модели распределения над обычной OCBA выбора лучшей альтернативы. При логнормальном шуме у OCBA меньше ошибок pbest, чем у RS, но хуже итоговое качество, поэтому простое объяснение через одну частоту ошибок не подтверждено. Абляция начального числа наблюдений и диагностика рекордов не идентифицируют причинный механизм. Сравнение с равномерным и обычным OCBA контролями остается необходимым.

Вклад работы эмпирический и методический: стандартизованная карта распределений, бюджета и роя, прямые условные контрасты средних, отделение пользы повторов от модели личных рекордов и независимое планирование NN объема. Последующий анализ и абляция обозначены как исследовательские; основные решения не переопределены.

На двух табличных наборах Ionosphere и Sonar с малым MLP в 8208 подтверждающих поисках при 456 парах на условие после Holm значимы 4 из 12 отличий от нуля, одно положительно и меньше 1 процентного пункта. Исследовательские тесты превышения среднего над 1 п.п. не отклоняют ни одной гипотезы. Двусторонние одновременные интервалы Bonferroni имеют верхнюю границу ниже 1 п.п. в 11 из 12 сравнений и во всех шести сравнениях с PSO-EA. В оставшемся сравнении с PSO верхняя граница равна 1,126 п.п. Поэтому отсутствие эффекта или универсальная бесполезность ОСВА в нейросетевом HPO не доказаны.

Протокол и доступность данных

Вычисления выполнены на CPU в Windows, Python 3.13.3, NumPy 2.3.5, SciPy 1.17.0, scikit-learn 1.8.0, pandas 2.2.3 и matplotlib 3.10.8. Численные потоки каждого процесса ограничены одним. Исходная серия содержит 35 280 поисков, 9 072 000 поисковых оценок и 2160 итоговых обучений. Дополнительная серия содержит 86 400 поисков и 298 598 400 поисковых оценок, включая отдельный пилот из 432 поисков и 233 280 оценок. Дополнительно выполнены 25 920 итоговых обучений новой нейросетевой серии и ее пилота. Пилот не участвует в подтверждающих сравнениях.

Сфокусированная n0 серия добавила 2160 поисков и 18 662 400 оценок. Проверка новых экземпляров добавляет 2880 поисков и 24 883 200 оценок. Итог всех научных серий: 126 720 поисков, 351 216 000 поисковых оценок и 28 080 финальных NN обучений. Технические smoke и bootstrap не входят в эти счетчики.

На Intel Core i5-14600K (14 физических ядер, 20 логических процессоров) сумма длительностей рабочих заданий дополнительной серии составила 40,850 ч: аналитическая часть 6,515 ч, нейросетевой пилот 1,238 ч, подтверждающая нейросетевая часть 33,097 ч. Итог вычислен по исходным неокругленным секундам, после чего части и сумма округлены до тысячных часа. Измерения time.perf_counter включают поиски, финальные обучения и запись журналов внутри задания, исключая подготовку задачи и последующий аудит. Задания выполнялись параллельно; сумма их длительностей не является процессорным временем, длительностью последовательного запуска или оценкой ускорения. CPU-время процессов и энергопотребление не измерялись. Сравнения качества при фиксированном реальном времени не проводились.

Новая проверка экземпляров добавила 0,2403 ч суммы длительностей рабочих заданий с записью журналов. Это астрономическое время выполнения задания, а не измеренное CPU-время.

Для n_0 абляции отдельно записано 0,337 ч суммы длительностей рабочих заданий. Это та же метрика астрономического времени выполнения с записью журналов, а не CPU-время.

В историческом снимке сохранены исполнявшиеся исходники и анализаторы. Архив содержит параметры преобразований, координаты точек, seed оценок, итоговые accuracy, числа правильных ответов и SHA-256 (Secure Hash Algorithm). Данные Ionosphere и Sonar получены из UCI с лицензией CC BY 4.0 (Creative Commons Attribution). Формулы текущего документа остаются редактируемыми Office Math.

experiment.py сохраняет основной запуск расширенной серии и исторические режимы. analyze_ocba_scope.py читает results/ocba_instances_20261022/runs.csv и results/ocba_robustness_20261022/synthetic_runs.csv; прежние средние находятся в results/ocba_mean_analysis_20261022/mean_contrasts.csv. Его результаты сохранены в results/ocba_scope_20261023. diagnose_ocba_traces.py читает evaluations.csv.gz, pools.csv.gz, runs.csv и complete.json в 32 каталогах results/ocba_instances_20261022/cells. Компактный пакет содержит все индивидуальные итоги и производные диагностики, но только пример исходных трасс трех поисков. audit_ocba_hierarchy.py проверяет распределение перевыборок по итоговому runs.csv; его результаты находятся в results/ocba_final_20261024. Текущую рукопись собирает build_ocba_publication_20261024.py. Проверка длительностей находится в results/ocba_editorial_20261024, а текущие редакционные отчеты - в results/ocba_publication_20261024. Замороженные оптимизаторы и старые планы не заменяются.

Подготовлен комплект ocba_reviewer_bundle_publication_20261024.zip с исходниками, версиями, протоколами, индивидуальными итогами, весами контрастов и примерами трасс. Внутренний аудит другой реализацией воспроизвел 1944 ранговых, 12 нейросетевых сравнений и bootstrap семейств 23 и 72 с максимальным расхождением менее 2e-15. Для bootstrap намеренно использованы один алгоритм генератора NumPy, одинаковые seed, размеры блоков и порядок генерации индексов, поэтому обе реализации получают одинаковые перевыборки. Независимо написана арифметика расчета, а не случайная выборка; указанная точность не относится к двум независимым Monte Carlo сериям. Другой seed проверен отдельно для иерархической диагностики. Совпадение проверяет согласованность реализаций на этих данных, не корректность всех предпосылок. Диагностика новой серии использует все ее 24 883 200 сохраненных вызовов. Полные исторические трассы целиком в компактный архив не входят. Независимое внешнее воспроизведение, публичная публикация и DOI (digital object identifier) пока отсутствуют.

Список литературы

1. Kennedy J., Eberhart R. Particle Swarm Optimization // Proceedings of ICNN'95. 1995. Vol. 4. P. 1942-1948. DOI: 10.1109/ICNN.1995.488968.
2. Clerc M., Kennedy J. The Particle Swarm: Explosion, Stability, and Convergence in a Multidimensional Complex Space // IEEE Transactions on Evolutionary Computation. 2002. Vol. 6, no. 1. P. 58-73. DOI: 10.1109/4235.985692.
3. Rada-Vilela J., Johnston M., Zhang M. Population Statistics for Particle Swarm Optimization: Resampling Methods in Noisy Optimization Problems // Swarm and Evolutionary Computation. 2014. Vol. 17. P. 37-59. DOI: 10.1016/j.swevo.2014.02.004.
4. Rada-Vilela J., Johnston M., Zhang M. Population Statistics for Particle Swarm Optimization: Hybrid Methods in Noisy Optimization Problems // Swarm and Evolutionary Computation. 2015. Vol. 22. P. 15-29. DOI: 10.1016/j.swevo.2015.01.003.
5. Zhang S., Xu J., Lee L. H., Chew E. P., Wong W. P., Chen C.-H. Optimal Computing Budget Allocation for Particle Swarm Optimization in Stochastic Optimization // IEEE Transactions on Evolutionary Computation. 2017. Vol. 21, no. 2. P. 206-219. DOI: 10.1109/TEVC.2016.2592185.
6. Rakshit P., Konar A., Das S. Noisy Evolutionary Optimization Algorithms: A Comprehensive Survey // Swarm and Evolutionary Computation. 2017. Vol. 33. P. 18-45. DOI: 10.1016/j.swevo.2016.09.002.
7. Bergstra J., Bengio Y. Random Search for Hyper-Parameter Optimization // Journal of Machine Learning Research. 2012. Vol. 13. P. 281-305. URL: https://www.jmlr.org/papers/v13/bergstra12a.html.
8. Bischl B. et al. Hyperparameter Optimization: Foundations, Algorithms, Best Practices, and Open Challenges // WIREs Data Mining and Knowledge Discovery. 2023. Vol. 13, no. 2. Article e1484. DOI: 10.1002/widm.1484.
9. Bouthillier X. et al. Accounting for Variance in Machine Learning Benchmarks // Proceedings of Machine Learning and Systems. 2021. Vol. 3. URL: https://proceedings.mlsys.org/paper_files/paper/2021/hash/0184b0cd3cfb185989f858a1d9f5c1eb-Abstract.html.

10. García S., Fernández A., Luengo J., Herrera F. Advanced Nonparametric Tests for Multiple Comparisons in the Design of Experiments in Computational Intelligence and Data Mining: Experimental Analysis of Power // Information Sciences. 2010. Vol. 180. P. 2044-2064. DOI: 10.1016/j.ins.2009.12.010.
11. Surjanovic S., Bingham D. Virtual Library of Simulation Experiments: Test Functions and Datasets. Simon Fraser University. URL: https://www.sfu.ca/~ssurjano/optimization.html (accessed 2026-10-22).
12. Sigillito V., Wing S., Hutton L., Baker K. Ionosphere [Dataset]. UCI Machine Learning Repository. 1989. DOI: 10.24432/C5W01B. License CC BY 4.0.
13. Sejnowski T., Gorman R. Connectionist Bench Sonar Mines vs. Rocks [Dataset]. UCI Machine Learning Repository. 1988. DOI: 10.24432/C5T01Q. License CC BY 4.0.
14. Инкижеков А. А., Дулесов А. С. Использование ройного интеллекта для оптимизации гиперпараметров нейронных сетей: сравнительный анализ на MNIST и CIFAR-10 // Modern Innovations, Systems and Technologies. 2024. Т. 4, № 2. С. 291-297. DOI: 10.47813/2782-2818-2024-4-2-0291-0297.
15. Reimers N., Gurevych I. Reporting Score Distributions Makes a Difference: Performance Study of LSTM-networks for Sequence Tagging // Proceedings of EMNLP. 2017. P. 338-348. DOI: 10.18653/v1/D17-1035.
16. Feurer M., Hutter F. Hyperparameter Optimization // Automated Machine Learning / eds. F. Hutter, L. Kotthoff, J. Vanschoren. Springer, 2019. P. 3-33. DOI: 10.1007/978-3-030-05318-5_1.
17. SciPy. SciPy 1.17.0 reference: scipy.stats.ttest_rel, scipy.stats.nct and scipy.stats.wilcoxon. URL: https://docs.scipy.org/doc/scipy-1.17.0/reference/generated/scipy.stats.ttest_rel.html; https://docs.scipy.org/doc/scipy-1.17.0/reference/generated/scipy.stats.nct.html; https://docs.scipy.org/doc/scipy-1.17.0/reference/generated/scipy.stats.wilcoxon.html (accessed 2026-10-22).
18. SciPy. SciPy 1.17.0 reference: scipy.stats.binomtest. URL: https://docs.scipy.org/doc/scipy-1.17.0/reference/generated/scipy.stats.binomtest.html (accessed 2026-10-22).
19. Wang S., Lu Z. Depth over Fidelity in Fixed-Budget Noisy Evolution Strategies // Proceedings of the 43rd International Conference on Machine Learning. PMLR. 2026. Vol. 306. P. 128714-128741. URL: https://proceedings.mlr.press/v306/wang26ff.html (accessed 2026-10-22).
20. Hansen N., Auger A., Ros R., Mersmann O., Tušar T., Brockhoff D. COCO: A Platform for Comparing Continuous Optimizers in a Black-Box Setting // Optimization Methods and Software. 2021. Vol. 36, no. 1. P. 114-144. DOI: 10.1080/10556788.2020.1808977. URL: https://coco-platform.org/ (accessed 2026-10-22).
21. Romano J. P., Wolf M. Stepwise Multiple Testing as Formalized Data Snooping // Econometrica. 2005. Vol. 73, no. 4. P. 1237-1282. DOI: 10.1111/j.1468-0262.2005.00615.x.
22. Virtanen P., Gommers R., Oliphant T. E. et al. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python // Nature Methods. 2020. Vol. 17. P. 261-272. DOI: 10.1038/s41592-019-0686-2.
23. Westfall P. H., Young S. S. Resampling-Based Multiple Testing: Examples and Methods for p-Value Adjustment. New York: Wiley, 1993. ISBN 978-0-471-55761-6.
24. Chauhan D., Shivani, Suganthan P. N. Learning Strategies for Particle Swarm Optimizer: A Critical Review and Performance Analysis // Swarm and Evolutionary Computation. 2025. Vol. 98. Article 102048. DOI: 10.1016/j.swevo.2025.102048.
25. Zhong P., Wu X., Zhu L., Yang A. A New APSO-SPC Method for Parameter Identification Problem with Uncertainty Caused by Random Measurement Errors // AIMS Mathematics. 2025. Vol. 10, no. 2. P. 3848-3865. DOI: 10.3934/math.2025179.
26. Choi S. H., Kim T. G. Enhancing the Noise Robustness of the Optimal Computing Budget Allocation Approach // IEEE Access. 2020. Vol. 8. P. 25749-25763. DOI: 10.1109/ACCESS.2020.2970864.
27. Chick S. E., Inoue K. New Two-Stage and Sequential Procedures for Selecting the Best Simulated System // Operations Research. 2001. Vol. 49, no. 5. P. 732-743. DOI: 10.1287/opre.49.5.732.10615.
28. Alpaydin E., Kaynak C. Optical Recognition of Handwritten Digits [Dataset]. UCI Machine Learning Repository. 1998. DOI: 10.24432/C50P49.
29. Aeberhard S., Forina M. Wine [Dataset]. UCI Machine Learning Repository. 1992. DOI: 10.24432/C5PC7J.
30. Wolberg W., Mangasarian O., Street N., Street W. Breast Cancer Wisconsin (Diagnostic) [Dataset]. UCI Machine Learning Repository. 1993. DOI: 10.24432/C5DW2B.